# **XML**



## Table des matières

Chapitre 1 : Le XML, qu'est-ce que c'est ?

Chapitre 2 : Syntaxe de base

Chapitre 3 : Définition de documents

Chapitre 4 : XPath



# LE XML, QU'EST-CE QUE C'EST?



#### XML?

- eXtensible Markup Language
  - Langage de balisage extensible
  - Balise : <NomBalise> ... </NomBalise>

```
<?xml version="1.0" encoding="UTF-8"</pre>
    -<Person>
 3
          <Name>Asimov</Name>
 4
          <FirstName>Isaac</FirstName>
 5
          <DateOfBirth>
 6
              <Day>2</Day>
              <Month>January</Month>
              <Year>1920</Year>
 9
          </DateOfBirth>
     </Person>
10
```



# **Objectif**

• Stockage de documents

Permet un stockage structuré d'une information ou d'un ensemble d'informations

Transmission de données

Permet une communication structurée entre des applications



## Historique

- 1986 SGML
  - Standard Generalized Markup Language
  - Destiné aux documentations techniques
  - Trop complexe à utiliser dans la plupart des circonstances
- 1991 HTML
  - HyperText Markup Language
  - Version (extrêmement) simplifiée du SGML
  - Utilisation ciblée



## Historique

- 1998 XML 1.0
  - Entre SGML et HTML
  - Simplification du SGML
  - Généralisation de l'HTML
  - Résultat : Langage plus simple et utilisable en toutes circonstances
- 2004 XML 1.1
  - Mise à jour
  - Prise en compte des caractères spéciaux



### Utilité

- Bureautique
  - Possibilité de stocker des documents Word ou Excel au format XML
- Dessins vectoriels
  - Le format SVG (Inkscape notamment) est stocké au format XML
- Fichiers de configuration
- AJAX (Bien que la tendance aille vers le JSON)
- Base de données XML



## Intérêts

- Séparation du contenu de de la présentation
  - De la même manière que l'HTML avec le CSS
  - L'HTML contient encore des balises de présentation
- Simplicité (lisible même par un non-initié)
- Généricité
- Structuration forte
- Format libre



## Quelques termes

Balise: <NomBalise>

Balise ouvrante : <NomBalise>

Balise fermante : </NomBalise>

Attribut : <NomBalise Attribut=«Valeur »>

Contenu: Texte entre une balise ouvrante et une fermante.

Peut contenir d'autres balises

Élément : Balises + Attributs + Contenu

Vocabulaire : Ensemble des balises existantes

Dialecte : Désigne un vocabulaire précis

Quelques uns de ces termes seront développés plus loin



#### Extensibilité

- Une des principales caractéristiques du XML
- XML != HTML :
  - Balises non-fixées
  - Ce sont les auteurs qui fixent leurs balises (et qui créent donc leur vocabulaire)
    - Nécessité pour les auteurs de s'accorder sur ce vocabulaire
- Contrepartie : Cette liberté dans la création du vocabulaire implique la création de règles afin de garder les documents cohérents



# SYNTAXE DE BASE



## Analyse d'un exemple

#### Fichier: FirstDocument.xml

```
1 <!-- Ceci est un commentaire -->
   <!-- Document réalisé dans le cadre du cours XML -->
   <?xml version="1.0" encoding="UTF-8" ?>
 5 P<!-- Première ligne réel d'un document XML
  On y définit la version du XML utilisée
   Ainsi que l'encodage du texte (Généralement ISOXXX ou UTF-8) -->
 8
    <!DOCTYPE [...]>
   <!-- DTD, cette partie est tronguée, elle sera vue par la suite -->
11
12 P<Character key="character01" >
13
    <!-- On déclare un élément "Person" dont la clé est "Character01" -->
14
        <Name>Majere</Name>
15
        <!-- Le nom du personnage est "Majere" -->
        <FirstName>Raistlin</FirstName>
16
17
        <!-- Le prénom du personnage est "Raistlin" -->
        <Class>Wizard</Class>
18
        <Level>48</Level>
19
21
    </Character>
    <!-- Chaque balise ouverte doit être fermée sans chevauchement ! -->
```



## Prologue

- Le prologue rassemble les lignes avant le nœud principal du document (lignes 1=>8)
- Il contient l'en-tête (ligne 4)
- Et également la déclaration du type de document (ligne 9)
- Et quelques commentaires, juste pour le plaisir

### En-tête

- Première ligne réelle d'un document XML
- Format <?xml[...]?>, ce n'est pas une balise
- Trois attributs:
  - version : Précise la version du XML utilisée
    - Valeurs possibles : « 1.0 », « 1.1 »
  - o encoding: Type de codage
    - Valeurs possibles: « iso-8859 », « utf-8 », « utf-16 »
  - o standalone: Précise si le fichier est autonome
    - Valeurs possibles : « yes », « no »

## Déclaration de type de document

- Toujours dans le prologue
- Format : <!DOCTYPE [...]>
- Permet de définir les règles (DTD) du documents
- Cette partie sera développée plus loin dans ce cours



## Corps du document

- Le corps du document contient les éléments :
  - <FirstName>Raistlin</FirstName>
  - o Cette ligne forme un élément nommé «FirstName» et dont le contenu est «Raistlin»
- Pas d'espace entre le chevron ouvrant (<) et le nom de la balise :</li>
  - < FirstName> : Cette balise n'est pas correcte
  - <FirstName > : Celle-ci l'est, les espaces après le nom sont autorisés
- Certains caractères réservés ne sont pas utilisables (pour l'instant) dans le texte du contenu (<, >, &)
- En cas de contenu vide tel quel : <FirstName></FirstName>
  - On peut utiliser une balise « auto-fermante » : <FirstName />



## Corps du document

Imbrication des éléments

- Un élément peut contenir d'autres éléments
- Pas de chevauchement!
  - < Person><Name>Asimov</Person></Name>



## Corps du document

- Tout le corps du document est compris dans le contenu d'un élément racine (ou nœud principale).
- Il s'agit des balises englobant la totalité du contenu.
- Une seule racine par document!



- Un attribut est un couple nom/valeur :
  - NomAttribut="ValeurAttribut"
- Les attributs se mettent dans la balise ouvrante (qui peut ne pas en contenir):
  - <NomBalise Attribut1="Valeur1" Attribut2="Valeur2" >
- Ce qui ne change pas la balise fermante :
  - </NomBalise>
- Souvent utilisés pour les méta-données (données sur les données).
  - <date format="dd/mm/yyyy">01/03/1995</date>

### Pour les noms XML

- Ils peuvent contenir des lettres/chiffres/caractères spéciaux (sauf ceux mentionnés plus haut)
- Ils doivent débuter par une lettre
- Ne pas commencer par les lettres « xml »
- Ne pas contenir d'espace



### **Exercice 1**

- Réalisez un document XML représentant une liste de livres.
- Chaque livre a un titre, un auteur (juste le nom/prénom), un genre et une date de publication.
- Extra: Si le livre est le 2<sup>ième</sup> d'une série, on doit pouvoir retrouver le premier.



#### Exercice 2

- On veut créer un document XML structurant les données d'un annuaire téléphonique.
- L'annuaire doit comprendre au moins 2 personnes. Pour chaque personne, on souhaite connaître les informations suivantes :
  - Son sexe (homme ou femme).
  - o Son nom.
  - Son prénom.
  - Son adresse.
  - Un ou plusieurs numéros de téléphone (téléphone portable, fixe, bureau, etc.).
  - Une ou plusieurs adresses e-mail (adresse personnelle, professionnelle, etc.).



# DÉFINITION DE DOCUMENTS



# Règles

- ullet Afin de garder une cohérence dans le document o Règles
- Exemple:
  - Our Une balise < Date > doit contenir :
    - <Day>, <Month>, <Year>
- Règles → Modèles de documents



# Règles

- Représentation de ces règles :
  - DTD (Document Type Définition)
  - Schémas
- Vérification d'un document XML :
  - Grâce aux modèles de documents
    - Notepad++ & XML Tool
    - Visual Studio Code & l'extension XML
    - XML Copy Editor
- Un document peut être bien formé mais invalide
  - o Bien formé : Respect de la syntaxe XML
  - Valide : Respect des règles définies dans le DTD ou le schéma XML



# DOCUMENT TYPE DEFINITION



- Les règles s'appliquant aux éléments ont cette syntaxe :
  - <!ELEMENT balise (contenu)>
    - balise : on indique la balise concernée
    - contenu : on indique le contenu qu'elle doit avoir
- Exemples:
  - <!ELEMENT character (#PCDATA)>
    - La balise « character » doit contenir un ensemble de caractères (PCDATA =
       Parsed Character DATA)
    - Remarque : ne pas oublier les parenthèses autour de #PCDATA



- Exemples:
  - <!ELEMENT character (name, firstname)>
    - La balise character DOIT contenir : une balise name (1 fois) ET une balise firstname (1 fois)
  - <!ELEMENT character (name | firstname)>
    - La balise character DOIT contenir une balise name (1 fois) OU une balise firstname (1 fois)

Remarque: les deux balises ne peuvent pas être présentes en même temps (~XOR)



- Exemples:
  - <!ELEMENT character(name, firstname?)>
    - La balise character DOIT contenir une balise name (1 fois) et PEUT contenir une balise firstname (0 ou 1 fois)
  - <!ELEMENT character (name, firstname\*)>
    - La balise character DOIT contenir une balise name (1 fois) et PEUT une balise firstname (0 ou plusieurs fois)
  - <!ELEMENT character(name, firstname+)>
    - La balise character DOIT contenir une balise name (1 fois) ET une balise firstname (1 ou plusieurs fois)



- Exemples:
  - <!ELEMENT character EMPTY>
    - La balise character DOIT être vide
  - <!ELEMENT character ANY>
    - La balise character peut contenir n'importe quoi NB : l'utilisation de ANY est à éviter

Remarque : Ces deux mots-clés peuvent s'utiliser sans parenthèses



- Evidemment les attributs ont aussi droit à leurs règles :
  - <!ATTLIST balise attribut (contenu) mode>
    - balise : on indique la balise concernée
    - attribut : on indique l'attribut concerné
    - contenu : on indique le contenu qu'elle doit avoir
    - mode : Permet d'indiquer si un élément est :
      - obligatoire (#REQUIRED)
      - facultatif (#IMPLIED)
      - fixé (#FIXED)

- Exemples:
  - <!ATTLIST character sexe CDATA #REQUIRED>
    - La balise character DOIT contenir un attribut sexe qui doit contenir une chaîne de caractères (CDATA = Character DATA)
  - <!ATTLIST character sexe (h|f) #REQUIRED>
    - La balise character DOIT contenir un attribut sexe qui doit contenir soit "h" soit "f"
  - <!ATTLIST character sexe (h|f) #IMPLIED>
    - La balise character PEUT contenir un attribut sexe qui doit contenir soit "h", soit "f"



- Exemples
  - <!ATTLIST character sexe CDATA #FIXED "h" >
    - La balise character DOIT contenir un attribut sexe qui doit contenir soit "h"
  - <!ATTLIST character key ID #REQUIRED>
    - La balise character DOIT contenir un attribut key qui doit être unique pour chaque balise character
  - <!ATTLIST character otherkey IDREF #IMPLIED>
    - La balise character PEUT contenir un attribut otherkey qui doit être correspondre à l'ID d'une des balises character



## **Emplacements**

- Nous avons vu un certain nombre de règles jusqu'ici mais où les écrire ?
  - Soit directement dans le fichier XML :
    - <!DOCTYPE NoeudPrincipal [Règle1 Règle2 Règle3 ...]>
  - Soit dans un fichier séparé avec l'extension .dtd
    - Dans ce cas il faut référencer ce fichier dans le fichier XML
      - <!DOCTYPE NoeudPrincipal SYSTEM "Chemin" >
    - Il faut également préciser dans le prologue que le fichier n'est pas autonome
      - <?xml version="1.0" encoding="UTF-8" standalone="no"?>

Il vaut toujours mieux utiliser un fichier séparé mais on peut mettre temporairement les règles dans le fichier XML sans soucis



## Exemple de DTD

dates.xml:

```
<?xml version="1.0" encoding="UTF-8" standalone="no"?>
    <!DOCTYPE dates SYSTEM "dates.dtd">
 3 ⊟ <dates>
 4 A (date)
        <time format="12-hour">6:00PM</time>
 6
        <day>17</day>
        <month>6</month>
 8
        <year>2014</year>
 9
      </date>
10 =
     <date>
       <time format="24-hour">17:00</time>
11
12
       <day>1</day>
       <month>1</month>
13
14
        <year>1970</year>
15
      </date>
16 -
     <date>
17
        <time format="24-hour">19:00</time>
        <day>25</day>
18
19
        <month>12</month>
        <year>0</year>
20
21
      </date>
    </dates>
```



#### Exemple de DTD

#### dates.dtd:

```
<!--Le noeud principal Dates peut contenir plusieurs A@lA@ments Date-->
    <!ELEMENT dates (date+)>
 3
 4
    <!--Chaque Ã@lÃ@ment Date est composÃ@ des Ã@lÃ@ments Day, Month et Year-->
    <!ELEMENT date (time, day, month, year)>
 5
 6
    <!--L'Ã@lÃ@ment Time possÃ"de un contenu non vide (#PCDATA)-->
    <!ELEMENT time (#PCDATA)>
8
9
10 ⊟<!--Il possÃ"de Ã@galement un attribut appelÃ@ format qui indique le format
11 de l'heure. Cet attribut est obligatoire, et il peut uniquement prendre
12 les valeurs "12-hour" ou bien "24-hour"-->
    <!ATTLIST time format (12-hour | 24-hour) #REQUIRED>
14
   <!--L'Ã@lÃ@ment Day possÃ"de un contenu non vide (#PCDATA)-->
15
16
    <!ELEMENT day (#PCDATA)>
17
18
    <!--L'Ã@lÃ@ment Month possÃ"de un contenu non vide (#PCDATA)-->
    <!ELEMENT month (#PCDATA)>
19
20
21
    <!--L'Ã@lÃ@ment Year possÃ"de un contenu non vide (#PCDATA)-->
22
   <!ELEMENT year (#PCDATA)>
```



#### Exercice

- Prenez le fichier « listCharacterDTD.xml » et son fichier DTD associé :
  - Regardez si vous comprenez la structure du fichier et si vous en comprenez les règles
  - Regardez s'il est bien formé, sinon, corrigez-le
  - Regardez s'il est valide, sinon, corrigez-le
  - N'hésitez pas à l'améliorer
- Reprenez l'exercice 1 corrigé de la liste de livre (qui doit maintenant être bien formé) et écrivez toutes les règles nécessaires afin de le rendre valide
- De même pour l'exercice 2 sur l'annuaire téléphonique



#### **Entités**

- Les règles DTD apportent une notion jusqu'alors inconnue : les entités
- Une entité est comparable à une constante
  - Alias / Valeur
- On spécifie l'entité à un ou plusieurs endroits dans le fichier XML puis on écrit sa règle DTD
- (II faut laisser la règle DTD dans le fichier XML et pas dans un fichier externe)



#### Entités

#### Les entités générales :

- Quelque part dans le fichier XML :
  - <class>&magic;</class>(magic est l'alias)
- Quelque part dans les règles :
  - <!ENTITY magic "Wizard" > (Wizard est la valeur)
- Dès lors, &magic; sera remplacé par "Wizard"
- Dans les entités générales, les alias sont précédés de & et suivi de ;



#### Entités

Avec les entités paramètres, les alias ne se trouvent pas dans le XML mais dans les règles

- Exemples:
  - <!ENTITY % listClass "class (Warrior|Wizard) #REQUIRED" >
  - <!ATTLIST character %listClass; >
- Résultat :
  - <!ATTLIST character class (Warrior|Wizard) #REQUIRED >

Attention : ne pas oublier l'espace entre % et listClass lors de la déclaration



#### **Défauts**

Les DTD (bien qu'encore très utilisés) ont quelques défauts :

- Nouveau format à apprendre (en plus du XML)
- Pas de typage :
   On peut préciser qu'un élément doit exister et s'il doit contenir quelque chose mais impossible de préciser si ce quelque chose doit être un int, un float, ...



# **SCHEMAS**



### **Avantages**

- Permet le typage des données
  - o On peut préciser ce qui est un int, ce qui est du texte, ...
- Permet de définir des contraintes plus précises que les DTD
- XML : Les schémas sont également écrits en XML!
   Ça tombe bien, on le connaît!



#### Base d'un schéma

Voila le contenu de base d'un schéma :

```
1 <?xml version="1.0" encoding="UTF-8"?>
2 \(\text{ < xsd: schema } \text{ xmlns: xsd} = "http://www.w3.org/2001/XMLSchema">
3 \(\text{ < / xsd: schema} \)</pre>
```

- La première ligne n'est plus à présenter
- La deuxième ligne est déjà un peu particulière, elle contient l'attribut « xmlns:xsd » qui n'est pas un attribut comme les autres



## Espace de noms

- Lors de la création de nos propres fichiers XML, on crée notre propre vocabulaire
- Pour créer un schéma standard, on va se servir de noms déjà définis, en important un vocabulaire ou espace de nom
- Les espaces de noms permettent également d'éviter des conflits de noms entre différents vocabulaires



#### Espace de noms

- Pour importer un espace de noms, il faut mettre comme attribut, dans le nœud principal :
  - xmlns="Namespace"(xmlns = XML NameSpace)
- Où on ajoutera un préfixe pour être sûr d'utiliser le nom venant de l'espace de noms "Namespace" :
  - xmlns:xsd="Namespace"
  - Cela signifie qu'avant d'utiliser chaque nom de cette espace de noms, il faut utiliser le préfixe xsd



#### Espace de noms

• Dès lors, l'instruction xmlns:xsd="http://www.w3.org/2001/XMLSchema" permet de définir un espace de noms qui aura comme préfixe xsd

```
1 <?xml version="1.0" encoding="UTF-8"?>
2 \(\text{<xsd:schema \timexmlns:xsd} = \text{"http://www.w3.org/2001/XMLSchema">}
3 \(\text{</xsd:schema>}
```

 La balise "schema" faisant partie de cet espace de noms, il faudra la précéder du préfixe xsd



### Espace de noms : remarques

- Le choix du préfixe est complètement arbitraire
- De même pour le nom de l'espace de noms : il n'est pas obligatoire de mettre un
   URL ; il faut juste que l'espace de nom soit identifié de manière unique par ce nom
- Si on ne précise pas de préfixe pour un espace de noms, celui-ci sera considéré comme l'espace de noms par défaut
- L'espace de nom est accessible pour l'élément qui déclare celui-ci, ainsi que tous ses sous-éléments



#### Espace de noms : portée

NS1.xml :

```
<?xml version="1.0" encoding="UTF-8"?>
2 = <html xmlns="http://www.w3.org/1999/xhtml">
      <!-- L'espace de noms par defaut est celui de XHTML -->
4 -
     <head>
     <title>Espaces de noms</title>
6
      </head>
7 🗏
     <body>
8 =
        <mml:math xmlns:mml="http://www.w3.org/1998/Math/MathML">
9 🗏
         <mml:apply>
10
          <mml:eq/>
  </mml:apply>
11
12
     </mml:math>
        <!-- L'espace de noms MathML n'est maintenant plus disponible -->
13
14
      </body>
    </html>
15
```



### Espace de noms : portée

NS2.xml

```
<?xml version="1.0" encoding="UTF-8"?>
 2 ⊟<html xmlns="http://www.w3.org/1999/xhtml">
      <!-- L'espace de noms par defaut est celui de XHTML -->
 4 -
     <head>
 5
      <title>Espaces de noms</title>
      </head>
      <body>
 7 🗏
        <math xmlns="http://www.w3.org/1998/Math/MathML">
 8 =
 9
          <!-- L'espace de noms par defaut est maintenant celui de MathML -->
10 -
         <apply>
11
         <eq/>
12
         </apply>
13
      <!-- L'espace de noms par défaut est à nouveau celui de XHTML -->
14
15
      </body>
    </html>
16
```



### Espace de noms : portée

NS3.xml

```
1 <?xml version="1.0" encoding="UTF-8"?>
 2 - <a href="http://www.w3.org/1999/xhtml">
      <!-- L'espace de noms par défaut est maitenant l'espace de noms XHTML -->
     <!-- Tous les éléments html, head, title, body, ... appartiennent
      à l'espace de noms XHTML qui est l'espace de noms par défaut. -->
      <head>
 6 -
      <title>Espaces de noms</title>
 8
      </head>
 9 -
      <body>
       <name xmlns="">
10 -
         <!-- L'espace de noms par défaut n'est plus spécifié -->
11
12 -
         <!-- Les trois éléments name, firstname et surname
13
         n'appartiennent à aucun espace de noms. -->
         <firstname>Gaston</firstname>
14
15
          <surname>Lagaffe</surname>
16
        </name>
17
      </body>
18
    </html>
```



#### Structure d'un schéma

Pour rappel, voici la structure de base d'un schéma

```
1 <?xml version="1.0" encoding="UTF-8"?>
2 \(\text{ < xsd: schema \cdot xmlns: xsd} = \text{"http://www.w3.org/2001/XMLSchema"} \)
3 \(\text{ < /xsd: schema} \)</pre>
```

- Pour définir le schéma, nous utiliserons les éléments qui sont définis dans l'espace de nom (associé au préfixe xsd ici)
- Le noeud principal d'un schéma sera toujours <xsd:schema></xsd:schema>
- Extension du fichier : .xsd



#### Référence à un schéma

 Dans le document XML, on ajoutera une instruction pour faire référence au schéma

```
1 <?xml·version="1.0" encoding="UTF-8"?>
2 <noeudPrincipal xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
3 \(\text{\text{xsi:noNamespaceSchemaLocation="nomDuSchema.xsd"}\)
4 \(</noeudPrincipal>\)
```

Pour cela, il faudra utiliser un autre espace de noms (associé au préfixe xsi ici)



## Exemple de schéma

Dates.xml

```
1 <?xml version="1.0" encoding="UTF-8" standalone="no"?>
 2 ⊡ <dates xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance" xsi:noNamespaceSchemaLocation="dates.xsd">
 3 ☐ <date>
        <time format="12-hour">6:00PM</time>
        <day>17</day>
 5
        <month>6</month>
 6
 7
        <year>2014</year>
      </date>
 8
      <date>
        <time format="24-hour">17:00</time>
10
        <day>1</day>
11
        <month>1</month>
12
13
        <year>1970</year>
      </date>
14
15 =
      <date>
        <time format="24-hour">19:00</time>
16
        <day>25</day>
17
        <month>12</month>
18
19
        <year>0</year>
      </date>
20
    </dates>
```



## Exemple de schéma

Dates.xsd

```
1 <?xml version="1.0" encoding="UTF-8"?>
2 2 <xsd:schema xmlns:xsd="http://www.w3.org/2001/XMLSchema">
      <!--Type Day-->
4 =
      <xsd:simpleType name="Day">
5 🖃
        <xsd:restriction base="xsd:positiveInteger">
6
          <xsd:maxInclusive value="31"/>
7
       </xsd:restriction>
8
      </xsd:simpleType>
9
      <!--Type Month-->
      <xsd:simpleType:name="Month">
10 =
        <xsd:restriction base="xsd:positiveInteger">
11 🖃
12
        <xsd:maxInclusive value="12"/>
13
       </xsd:restriction>
14
      </xsd:simpleType>
15
      <!--Balise dates-->
16 🗏
      <xsd:element name="dates">
        <xsd:complexType>
17 🖃
18 -
          <xsd:sequence>
         <xsd:element ref="date" max0ccurs="unbounded"/>
20
         </xsd:sequence>
       </xsd:complexType>
22
      </xsd:element>
      <!--Balise date-->
      <xsd:element name="date">
25 🗏
        <xsd:complexType>
26 □
          <xsd:sequence>
27
            <xsd:element ref="time"/>
            <xsd:element name="day" type="Day"/>
28
29
            <xsd:element name="month" type="Month"/>
30
            <xsd:element name="year" type="xsd:int"/>
31
          </xsd:sequence>
32
       </xsd:complexType>
33
      </xsd:element>
      <!--Balise time-->
      <xsd:element name="time">
36 ⊟
        <xsd:complexType mixed="true">
37
       <xsd:attribute name="format" type="xsd:string" use="required"/>
38
       </xsd:complexType>
      </xsd:element>
    </xsd:schema>
```



#### Déclaration d'éléments

- TOUS les éléments qui apparaissent dans le document XML devront être déclarés dans le schéma
- Pour déclarer un élément, nous aurons besoin de définir son "type". Celui-ci va définir ce que cet élément pourra contenir



## Type nommé

- Déclaration :
  - <xsd:element name="nom" type="type"/>
    - nom est le nom de l'élément
    - type est un type nommé c'est-à-dire soit un type prédéfini, soit un type que nous avons défini nous-même (voir suite du plus loin)
- Liste complète des types prédéfinis :

http://www.w3.org/TR/xmlschema-2/#built-in-primitive-datatypes



## Type nommé

- Quelques exemples de types prédéfinis :
  - numérique : xsd:boolean, xsd:int, xsd:long, xsd:integer, xsd:float, xsd:double, xsd:decimal, ...
  - o chaînes de caractères : xsd:string, ...
  - heures et dates :
    - xsd:time (format hh:mm:ss[.sss][TZ]), ex: 14:07:23, 14:07:23-07:00
    - xsd:date (format YYYY-MM-DD), ex : 2008-01-16
    - xsd:dateTime (format YYYY-MM-DDThh:mm:ss), ex : 2008-01-16T14:07:23
    - xsd:duration (format P[nY]nM]nDT]nH]nM]nS]), ex: P1Y6M, P1M12DT2H et P1YD3H10S
    - ...
- Exemples

```
1 <xsd:element name="nomPerso" type="xsd:string"/>
```

2 <xsd:element name="endurance" type="xsd:int"/>



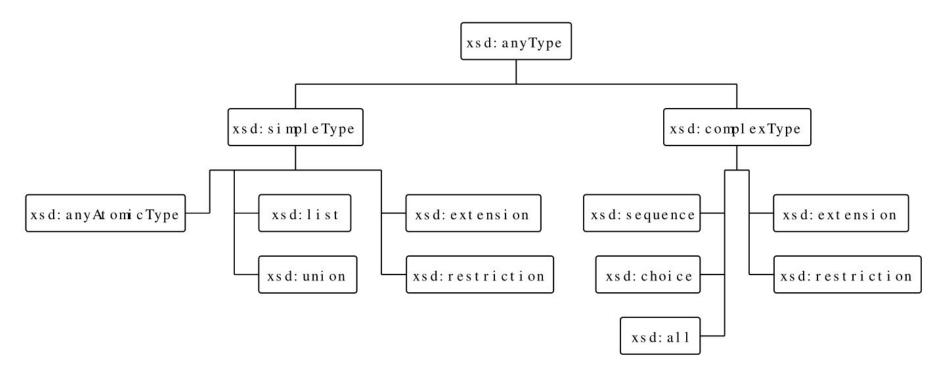
#### Valeur par défaut et valeur fixe

- Il est également possible de donner des valeurs par défaut avec l'attribut default, ainsi que des valeurs fixes avec l'attribut fixed
- Exemples



## Définir son type

Hiérarchie de construction des types





## Types simples

- Les types simples (xsd:simpleType) définissent uniquement des contenus textuels. Ils ne peuvent donc pas contenir d'autres éléments
- Ils peuvent être utilisés pour les éléments et les attributs, et il est possible de modifier un type existant avec les éléments xsd:restriction et xsd:extension et l'attribut base (voir plus loin)



#### Types simples

#### • Exemple

```
1 <?xml version="1.0" encoding="UTF-8" standalone="no"?>
2 <month xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
3 \(\text{xsi:noNamespaceSchemaLocation="test1.xsd"}\)
4 | 5
5 | </month>
```



#### Type anonyme

 Au lieu d'utiliser un type nommé, on peut déclarer le type en même temps que l' élément

```
1 = <xsd:element name="element">
     <xsd:simpleType>
        <!--Definition du type simple ici-->
 3
      </xsd:simpleType>
 4
    </xsd:element>
 5
 6
 7
  F<xsd:element name="element">
      <xsd:complexType>
11
        <!--Definition du type complexe ici-->
      </xsd:complexType>
12
     /xsd:element>
```



## Type anonyme

Exemple précédent avec un type anonyme



### Types complexes

- Les types complexes (xsd:complexType) définissent des contenus purs (contient uniquement des sous-éléments), des contenus textuels ou des contenus mixtes
- Ils ne peuvent être utilisés que pour les éléments
- Comme les types simples, il est possible de dériver d'un type existant avec l'attribut base
- Pour le construire, il faut utiliser les opérateurs de séquence (xsd:sequence), de choix (xsd:choice) ou d'ensemble (xs:all) que nous verrons plus en détails juste après



## Types complexes

#### Exemple

```
1 <?xml version="1.0" encoding="UTF-8" standalone="no"?>
   xml
          2 <date xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"</pre>
          3 □xsi:noNamespaceSchemaLocation="test1.xsd">
               <day>1</day>
             <month>1</month>
               <year>1970</year>
          7 </date>
0
   xsd
          1 <?xml version="1.0" encoding="UTF-8"?>
          2 □ < xsd:schema xmlns:xsd="http://www.w3.org/2001/XMLSchema">
               <xsd:element name="date">
          4 ⊟
                 <xsd:complexType>
                   <xsd:sequence>
                     <xsd:element name="day" type="xsd:int"/>
                     <xsd:element name="month" type="xsd:int"/>
                     <xsd:element name="year" type="xsd:int"/>
                   </xsd:sequence>
                 </xsd:complexType>
         10
               </xsd:element>
              /xsd:schema>
```



## Opérateur de séquence

• L'opérateur de séquence xsd:sequence permet de former une suite d'éléments

• "Équivalent" DTD:

<!ELEMENT date (time, day, month, year)>



## Opérateur de séquence

- Remarque : les éléments doivent apparaître dans le même ordre que celui défini dans l'élément xsd:sequence !
- Il est également possible de définir le nombre min et max d'apparition de chacun des éléments avec les attributs minOccurs et maxOccurs

```
24 -
      <xsd:element name="date">
25 -
        <xsd:complexType>
          <xsd:sequence>
26 -
27
          <!--La valeur unbounded signifie pas de limites-->
            <xsd:element ref="time" minOccurs="0" maxOccurs="unbounded"/>
28
            <xsd:element name="day" type="Day" minOccurs="2" maxOccurs="3"/>
29
            <xsd:element name="month" type="Month" minOccurs="2"/>
30
            <xsd:element name="year" type="xsd:int" maxOccurs="3"/>
31
          </xsd:sequence>
32
33
        </xsd:complexType>
      </xsd:element>
34
```



## Opérateur de choix

• Le contenu doit être l'un des éléments de l'élément xsd:choice

• "Équivalent" DTD:

<!ELEMENT publication (book | article | report)>



## Opérateur de choix

• On peut également utiliser les attributs minOccurs et maxOccurs

```
<xsd:element name="date">
24 -
25 -
        <xsd:complexType>
26 -
          <xsd:choice>
27
          <!--La valeur unbounded signifie pas de limites-->
            <xsd:element ref="time" maxOccurs="unbounded"/>
28
            <xsd:element name="day" type="Day" maxOccurs="unbounded"/>
29
            <xsd:element name="month" type="Month" maxOccurs="unbounded"/>
30
            <xsd:element name="year" type="xsd:int" max0ccurs="unbounded"/>
31
32
          </xsd:choice>
        </xsd:complexType>
33
        /xsd:element>
34
```

Attention : cela signifie que l'on peut avoir plusieurs éléments time OU plusieurs éléments day OU plusieurs éléments month OU plusieurs éléments year



#### **Imbrication**

On peut imbriquer plusieurs types. Que signifie le bout de schéma suivant?

```
1 P<xsd:element name="book" minOccurs="1" maxOccurs="unbounded">
      <xsd:complexType>
 3 =
        <xsd:sequence>
 4
          <xsd:element name="title" type="xsd:string"/>
 5 -
          <xsd:choice>
 6
            <xsd:element name="author" type="xsd:string"/>
            <xsd:element name="authors">
 7 -
 8 =
              <xsd:complexType>
 9 🗏
                <xsd:sequence>
                   <xsd:element name="author" type="xsd:string"</pre>
10
                   minOccurs="2" maxOccurs="unbounded"/>
11
                </xsd:sequence>
12
              </xsd:complexType>
13
            </xsd:element>
14
          </xsd:choice>
15
          <xsd:element name="year" type="xsd:string"/>
16
17
        </xsd:sequence>
18
      </xsd:complexType>
    </xsd:element>
```



## Opérateur d'ensemble

- L'opérateur d'ensemble est donné par l'élément xsd:all
- Il définit une liste d'éléments, chacun devant apparaître 1 fois (ou entre 0 et 1 fois si minOccurs="0")
- Le maxOccurs ne peut pas être différent de 1
- L'ordre d'apparition des éléments n'a pas d'importance
- On ne peut pas imbriquer les opérateur xsd:all dans d'autres constructeurs (xsd:sequence, xsd:choice et xsd:all)



## Opérateur d'ensemble

• Exemple



## Référencer un élément global

- Un élément global est un élément qui est enfant direct de l'élément xsd:schema
- Il est possible de référencer un élément global déjà défini avec l'attribut ref



## Référencer un élément global

```
1 <?xml version="1.0" encoding="UTF-8"?>
xsd
       2 □ < xsd:schema xmlns:xsd="http://www.w3.org/2001/XMLSchema">
            <xsd:element name="date">
       3 ⊟
              <xsd:complexType>
       4 □
                <xsd:sequence>
       5 □
                  <xsd:element name="day" type="xsd:int"/>
                  <xsd:element name="month" type="xsd:int"/>
                  <xsd:element name="year" type="xsd:int"/>
       8
                </xsd:sequence>
              </xsd:complexType>
      10
            </xsd:element>
      11
      12 □
            <xsd:element name="person">
              <xsd:complexType mixed="true">
      13 ⊟
                <xsd:sequence>
      14 □
      15
                  <xsd:element ref="date"/>
                </xsd:sequence>
      16
              </xsd:complexType>
      17
      18
            </xsd:element>
          </xsd:schema>
```



## Éléments locaux

• Il est possible de définir deux éléments ayant le même nom, mais des types différents pour autant qu'ils ne soient pas globaux

```
1 <?xml version="1.0" encoding="ISO-8859-1" standalone="yes"?>
xml
        <lists xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"</pre>
      3 □xsi:noNamespaceSchemaLocation="test1.xsd">
          <strings>
     4 □
            <local>Une chaîne</local>
            <local>A string</local>
     6
          </strings>
          <integers>
            <local>-1</local>
            <local>1</local>
    10
          </integers>
    11
        </lists>
```



## Éléments locaux

1 <?xml version="1.0" encoding="ISO-8859-1"?> Exemple 2 = < xsd: schema xmlns: xsd = "http://www.w3.org/2001/XMLSchema"> <xsd:element name="strings"> 3 ⊟ xsd 4 ⊟ <xsd:complexType> 5 ⊟ <xsd:sequence> <!-- Déclaration du premier élément local --> <xsd:element name="local" type="xsd:string" maxOccurs="unbounded"/> 8 </xsd:sequence> 9 </xsd:complexType> 10 </xsd:element> <xsd:element name="integers"> 11 ⊟ 12 □ <xsd:complexType> 13 □ <xsd:sequence> <!-- Déclaration du second élément local --> 14 <xsd:element name="local" type="xsd:integer" maxOccurs="unbounded"/> 15 16 </xsd:sequence> 17 </xsd:complexType> 18 </xsd:element> 19 □ <xsd:element name="lists"> 20 □ <xsd:complexType> 21 ⊟ <xsd:sequence> 22 <xsd:element ref="strings"/> <xsd:element ref="integers"/> 23 24 </xsd:sequence> 25 </xsd:complexType>

</xsd:element>

</xsd:schema>

26



#### Contenu mixte

- Le contenu d'un élément est pur s'il contient uniquement des sous-éléments
- Le contenu d'un élément est mixte s'il contient à la fois des sous-éléments et du contenu textuel
- Il faut alors rajouter l'attribut mixed="true" pour les types complexes
- Remarque : le cas ne se présente pas pour les types simples étant donné qu'il ne peuvent pas contenir de sous-éléments



#### Contenu mixte

```
1 <?xml version="1.0" encoding="UTF-8"?>
xml
      2 <person xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
      3□ xsi:noNamespaceSchemaLocation="test1.xsd">
      4 | Prénom : <firstname > Albert </firstname > ,
      5 | Nom :<lastname>Einstein</lastname>.
      6 </person>
       1 <?xml version="1.0" encoding="UTF-8"?>
xsd
       2 □ < xsd:schema · xmlns:xsd="http://www.w3.org/2001/XMLSchema">
            <xsd:element name="person">
       3 □
               <xsd:complexType mixed="true">
       4 □
                 <xsd:sequence>
       5 ⊟
       6
                   <xsd:element name="firstname" type="xsd:string"/>
                   <xsd:element name="lastname" type="xsd:string"/>
                 </xsd:sequence>
       8
       9
               </xsd:complexType>
            </xsd:element>
      10
          </xsd:schema>
```



- Les attributs sont toujours des types simples (xsd:simpleType) car ils ne contiennent que du contenu textuel
- Exemple de déclaration
   <xsd:attribute name="nom" type="type"/>
  - o nom est le nom de l'attribut
  - type est son type (type nommé)



Exemple (avec un attribut age)

```
1 <?xml version="1.0" encoding="UTF-8"?>
xml
       2 <person xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"</pre>
       3 ☐ xsi:noNamespaceSchemaLocation="test1.xsd" age="15">
       4 | Prénom : <firstname > Albert < / firstname > ,
       5 | Nom :<lastname>Einstein</lastname>.
      6 </person>
       1 <?xml version="1.0" encoding="UTF-8"?>
xsd
       2 ⊟ < xsd:schema xmlns:xsd="http://www.w3.org/2001/XMLSchema">
            <xsd:element name="person">
        3 □
              <xsd:complexType mixed="true">
        4 □
        5 ⊟
                 <xsd:sequence>
                  <xsd:element name="firstname" type="xsd:string"/>
        7
                   <xsd:element name="lastname" type="xsd:string"/>
       8
                </xsd:sequence>
                 <xsd:attribute name="age" type="xsd:int"/>
       10
              </xsd:complexType>
            </xsd:element>
       11
          </xsd:schema>
```



 Ils peuvent également être déclarés avec un type que nous avons défini (toujours xsd:simpleType pour les attributs!)

```
1 <?xml version="1.0" encoding="UTF-8"?>
 2 □ < xsd:schema xmlns:xsd="http://www.w3.org/2001/XMLSchema">
     <xsd:simpleType name="Age">
       <xsd:restriction base="xsd:positiveInteger">
         <xsd:maxInclusive value="150"/>
       </xsd:restriction>
     </xsd:simpleType>
     <xsd:element name="person">
       <xsd:complexType mixed="true">
9 □
10 □
         <xsd:sequence>
           <xsd:element name="firstname" type="xsd:string"/>
11
           <xsd:element name="lastname" type="xsd:string"/>
12
        </xsd:sequence>
13
         <xsd:attribute name="age" type="Age">
14 □
15
         </xsd:attribute>
       </xsd:complexType>
16
     </xsd:element>
17
18 </xsd:schema>
```



Même remarque avec un type anonyme

```
1 <?xml version="1.0" encoding="UTF-8"?>
 2 □ < xsd:schema xmlns:xsd="http://www.w3.org/2001/XMLSchema">
     <xsd:element name="person">
 3 ⊟
       <xsd:complexType mixed="true">
 4 □
          <xsd:sequence>
 5 □
 6
            <xsd:element name="firstname" type="xsd:string"/>
 7
            <xsd:element name="lastname" type="xsd:string"/>
8
          </xsd:sequence>
          <xsd:attribute name="age">
9 □
            <xsd:simpleType>
10 □
              <xsd:restriction base="xsd:positiveInteger">
11 □
                <xsd:maxInclusive value="150"/>
12
              </xsd:restriction>
13
            </xsd:simpleType>
14
          </xsd:attribute>
15
       </xsd:complexType>
16
17
     </xsd:element>
   </xsd:schema>
```



- Grâce à l'attribut use, on peut préciser si l'attribut obligatoire (required)
- On peut aussi donner des valeurs par défaut ou des valeurs fixes



### Extension de types

- Extension ~ héritage en orienté objet : rajouter des attributs ou des éléments
- Utilise l'élément xsd:extension
- Trois cas :
  - Types simples
  - (Types complexes à contenu simple)
  - (Types complexes à contenu complexe)



## Types simples

- Rappel: type simple = uniquement contenu textuel
- Avec l'extension on peut uniquement ajouter des attributs au type simple
- Le type obtenu est alors un type complexe à contenu simple
- Remarque : ce type simple peut être un type prédéfini ou bien un type qui nous avons défini (simpleType)



### Types simples

Exemple (extension de xsd:decimal)

```
xml (partiel)
1 <price currency="euro">3.14</price>
    xsd (partiel)
1⊟<xsd:complexType name="Price">
     <xsd:simpleContent>
2 ⊟
       <xsd:extension base="xsd:decimal">
3 ⊟
           <!-- Attribut ajouté -->
           <xsd:attribute name="currency" type="xsd:string"/>
5
6
         </xsd:extension>
       </xsd:simpleContent>
     </xsd:complexType>
9 <xsd:element name="price" type="Price"/>
```



## Types complexes

 Si un type complexe est obtenu par extension ou restriction d'un autre type, il faut rajouter l'éléments xsd:simpleContent si le contenu est purement textuel, et l' élément xsd:complexContent sinon

```
<!-- Type dérivé à contenu textuel -->
 2 ⊟<xsd:complexType ...>
      <xsd:simpleContent>
     <!-- Extension ou restriction -->
      </xsd:simpleContent>
6
    </xsd:complexType>
78
    <!-- Type dérivé à contenu pur ou mixte -->
10 □ <xsd:complexType ...>
11 	☐ ⟨xsd:complexContent⟩
      <!-- Extension ou restriction -->
12
13
      </xsd:complexContent>
    </xsd:complexType>
```



#### Restriction de types

- Restriction : on dérive d'un type de base pour rajouter des restrictions grâce à l' élément xsd:restriction et on utilise l'attribut base pour spécifier de quel type on dérive
- Types simples
  - Restriction par intervalle
  - Restriction par énumération
- (Types complexes à contenu simple)
- (Types complexes à contenu complexe)



#### Restriction de types

- Pour les types simples, l'élément xsd:restriction est enfant direct de l'élément xsd:simpleType
- Pour les types complexes :
  - enfant direct de xsd:simpleContent si contenu simple (= uniquement contenu textuel + attributs éventuels)
  - enfant direct de xsd:complexContent si contenu complexe (= contenu textuel + sous-éléments + attributs éventuels)



## Type simple: restriction par intervalle

- On utilise les éléments (chacun prend un attribut value)
  - xsd:minInclusive : valeur minimale inclusive
  - xsd:minExclusive : valeur minimale exclusive
  - xsd:maxInclusive : valeur maximale inclusive
  - xsd:maxExclusive : valeur maximale exclusive
- Exemple pour un élément (type simple)



#### Type simple: restriction par intervalle

Exemple pour un attribut (toujours type simple pour attribut)



## Type simple: restriction par énumération

On utilise l'élément xsd:enumeration (et l'attribut value)

```
<xsd:simpleType name="PhoneType">
  <xsd:restriction base="xsd:string">
    <xsd:enumeration value="home"/>
    <xsd:enumeration value="work"/>
  </xsd:restriction>
</xsd:simpleType>
<xsd:element name="phone">
  <xsd:complexType>
    <xsd:simpleContent>
      <xsd:extension base="xsd:string">
        <xsd:attribute name="type"/>
      </xsd:extension>
    </xsd:simpleContent>
  </xsd:complexType>
</xsd:element>
```



#### Type simple: autres restrictions

- Quelques autres éléments (chacun avec un attribut value) que l'on peut mettre dans xsd:restriction :
  - xsd:length, xsd:minLengthet xsd:maxLength : restriction sur la taille des strings
  - xsd:fractionDigitset xsd:totalDigits : nombre de chiffres après la virgule, et nombre total de chiffres respectivement
  - xsd:pattern : pour définir une expression régulière (regexp)



#### **Exercices**

- Reprenez l'exercice 1 de la liste de livre et écrivez le schéma le plus complet possible
- De même pour l'exercice 2 sur l'annuaire téléphonique



## **XPATH**



#### **XPATH**

- XPATH (XML PATH = Chemin XML)
- Technologie permettant d'extraire des données d'un documents XML :
  - Elements
  - Attributs
  - Commentaires
  - o ..



#### Arbre

- Il faut considérer le document XML comme un arbre :
  - Parent : Nœud directement au dessus du nœud courant
  - Enfants: Nœuds directement en dessous du nœud courant
  - Descendants: Tous les nœuds en dessous du nœud courant (peu importe le niveau)
  - Ancêtres : Tous les nœuds au dessus du nœud courant peu importe le niveau
  - Frères : Nœuds se trouvant sur le même niveau



## Recherche par étape

- On parcourt l'arbre par étapes successives
  - o /child::listCharacter/Character[attribute::key="character02"]/FirstName
- On peut avoir autant d'étapes que nécessaire



#### Type de chemin

Le type de chemin départ du départ :

- Chemin absolu :
   Le nœud de départ est la racine de l'arbre XML (Commence par « / » )
- Chemin relatif :
   Le nœud de départ peut être n'importe quel nœud de l'arbre XML



## Etape

- Une étape est décomposée en trois partie :
  - o Axe
  - Nœud
  - Prédicats
- Le format d'une étape :
  - Axe::nœud[prédicat][prédicat]...

#### Axe

- Détermine le sens de la recherche (haut, bas, niveau, ...) :
  - Parmi les valeurs possibles on retrouvera notamment : ancestor, attribute, child, descendant, parent, preceding, following, self



#### Noeuds

- Une fois la « direction » de la recherche définie, on va déterminer l'objet de la recherche :
- Parmi les valeurs possibles :
  - o Le nom d'un nœud précis : indique quel nœud doit être recherché
  - \*: recherche dans tous les types de nœuds
  - o node(): recherche dans tous les nœuds contenant simplement du texte
  - Comment(): recherche vers les nœuds de commentaire



#### **Prédicat**

- Permet d'affiner la recherche :
  - o II peut y en avoir plusieurs à la suite mais également aucun
- Type de prédicat :
  - o attribute : permet une recherche en fonction de l'attribut
  - count(): permet de compter le nombre de nœud
  - last(): permet de sélectionner le dernier nœud
  - o position(): permet de sélectionner un nœud en fonction de sa position



#### Références

- L'essentiel de XML Olivier Carton :
   <a href="http://www.liafa.jussieu.fr/~carton/Enseignement/XML/Cours/support.pdf">http://www.liafa.jussieu.fr/~carton/Enseignement/XML/Cours/support.pdf</a>
- Lien intéressant :
   <a href="http://fr.openclassrooms.com/informatique/cours/structurez-vos-donnees-avec-xml">http://fr.openclassrooms.com/informatique/cours/structurez-vos-donnees-avec-xml</a>



# Merci pour votre attention.

